ĐẠI HỌC QUỐC GIA TP.HCM

TRƯỜNG ĐẠI HỌC KHOA HỌC TỰ NHIÊN

KHOA CÔNG NGHỆ THÔNG TIN

BÁO CÁO BÀI TẬP THỰC HÀNH 2

Nhập môn Xử lý ngôn ngữ tự nhiên - 23CNTThuc2

Fine-tune Deepseek-OCR with Vietnamese Dataset

Giảng viên hướng dẫn: Đinh Điền
Nguyễn Hồng Bửu Long
Lương An Vinh

Sinh viên thực hiện: 23127485 – Phạm Quang Thịnh

TP. Hồ Chí Minh – 2025

Mục lục

1. Giới thiệu

Trong lĩnh vực Xử lý ngôn ngữ tự nhiên, bài toán Nhận dạng ký tự quang học (OCR) cho tiếng Việt luôn đặt ra nhiều thách thức đặc thù so với các ngôn ngữ Latin khác. Mặc dù các Mô hình Ngôn ngữ Đa phương thức Lớn (LMMs) hiện đại đã đạt được nhiều thành tựu, việc ứng dụng trực tiếp chúng vào văn bản tiếng Việt vẫn gặp hai trở ngại lớn:

1. **Độ phức tạp của hệ thống chữ viết:** Tiếng Việt sở hữu hệ thống dấu thanh phong phú (sắc, huyền, hỏi, ngã, nặng) và các nguyên âm có dấu (ă, â, ê, ô, ơ, ư). Sự chồng chéo của các dấu này, đặc biệt trong **văn bản viết tay hoặc ảnh chất lượng thấp**, dễ gây nhầm lẫn cho máy tính.
2. **Hạn chế của mô hình nền tảng:** Các mô hình LMM phổ biến hiện nay (như Llama-Vision, Qwen-VL...) thường được huấn luyện chủ yếu trên tập dữ liệu tiếng Anh hoặc tiếng Trung. Do đó, chúng thiếu "tri thức" sâu về hình thái ngữ pháp tiếng Việt, dẫn đến tỷ lệ lỗi ký tự (CER) cao khi phải xử lý các văn bản tiếng Việt thuần túy mà chưa qua tinh chỉnh.

Đồ án này tập trung giải quyết vấn đề trên bằng phương pháp tinh chỉnh (Fine-tuning) mô hình **DeepSeek-OCR** sử dụng bộ dữ liệu tiếng Việt chuyên biệt. Áp dụng kỹ thuật **QLoRA** để tối ưu hóa quá trình huấn luyện trên tài nguyên hạn chế, với mục tiêu chính là giảm thiểu sai sót nhận dạng và nâng cao độ chính xác tổng thể của mô hình.

2. Phương pháp luận

2.1. Chuẩn bị dữ liệu (Data Preparation)

Dữ liệu đóng vai trò cốt lõi trong việc tinh chỉnh mô hình. Quy trình xử lý dữ liệu được thực hiện qua các bước sau:

- **Thu thập:** Sử dụng bộ dữ liệu ảnh chữ viết tay tiếng Việt kèm nhãn (ground truth) tương ứng (bộ dữ liệu **UIT_HWDB_line** được gợi ý trong đề).
- **Tiền xử lý văn bản:** Chuẩn hóa toàn bộ nhãn văn bản về định dạng Unicode NFC, chuyển về chữ thường (lowercase) và loại bỏ các khoảng trắng thừa để đảm bảo tính nhất quán khi tính toán hàm mất mát (Loss). Sử dụng `DeepSeekOCRDataCollator` để chuẩn hóa kích thước ảnh (base size 1024, patch size 640) và tạo mask cho văn bản tiếng Việt.
- **Định dạng đầu vào:** Dữ liệu được chuyển đổi sang định dạng JSONL (Conversation format) phù hợp với các mô hình VLM:
  - *Input:* Ảnh + Prompt hướng dẫn ("<image>\Free OCR.").
  - *Output:* Văn bản tiếng Việt trong ảnh.
- **Phân chia dữ liệu (Data Splitting):** Để đảm bảo tính khách quan và kiểm soát hiện tượng overfitting, tập dữ liệu được phân chia thành 3 phần riêng biệt:
  - *Train set:* **3.200 mẫu** - Được sử dụng chính để cập nhật trọng số của mô hình.
  - *Validation set:* **150 mẫu** - Được sử dụng để đánh giá định kỳ trong quá trình huấn luyện nhằm theo dõi hàm mất mát (Loss) và lựa chọn checkpoint tối ưu.
  - *Test set:* **400 mẫu** - Được giữ độc lập hoàn toàn (unseen data), không tham gia vào quá trình học, dùng để tính toán chỉ số CER/WER cuối cùng cho báo cáo.

2.2. Kỹ thuật Huấn luyện

Để giải quyết bài toán huấn luyện mô hình lớn trên tài nguyên hạn chế (Google Colab T4 - 16GB VRAM), thư viện **Unsloth** kết hợp với kỹ thuật **QLoRA** (Quantized Low-Rank Adaptation) được sử dụng cho bài toán này. Cụ thể:

- **4-bit Quantization:** Mô hình gốc được nén (load) ở độ chính xác 4-bit, giúp giảm dung lượng VRAM tiêu thụ từ 15GB xuống còn 6-7GB mà vẫn giữ được hiệu năng gần tương đương 16-bit, cho phép chạy được trên GPU T4.
- **LoRA Adapters:** Thay vì cập nhật toàn bộ tham số của mô hình (Full Fine-tuning), ta đóng băng (freeze) mô hình gốc và chỉ huấn luyện các ma trận trọng số nhỏ (Adapters) được gắn thêm vào các lớp Attention (q_proj, k_proj, v_proj, o_proj).

2.3. Cấu hình Thực nghiệm

Các tham số siêu hình (Hyperparameters) được thiết lập như Bảng 1 dưới đây nhằm đảm bảo sự ổn định và tối ưu hóa hàm mất mát:

Bảng 1: Các tham số huấn luyện chi tiết

Tham số	**Giá trị thiết lập**
Framework	Unsloth (PyTorch + Transformers)
Phương pháp tối ưu (Optimizer)	AdamW 8-bit
Learning Rate	2×10^{-4} (Linear Schedule)
Batch Size (per device)	2
Gradient Accumulation Steps	4 (Tương đương Batch size tổng = 8)
Số bước huấn luyện (Max Steps)	150
Độ chính xác (Precision)	FP16 (Mixed Precision)
Evaluation Strategy	Steps (Mỗi 10 bước đánh giá 1 lần)

3. Thực nghiệm và Đánh giá

3.1. Thiết lập thí nghiệm

Quy trình thực nghiệm được thiết kế nhằm so sánh công bằng hiệu năng giữa mô hình gốc (Baseline) chưa qua chỉnh sửa và mô hình sau khi tinh chỉnh (Fine-tuned). Các thí nghiệm được thực hiện trên cùng một tập dữ liệu kiểm tra (Test set) gồm **400 mẫu** độc lập.

Môi trường thực nghiệm được triển khai trên nền tảng Google Colab với cấu hình phần cứng:

- **GPU:** NVIDIA Tesla T4 (16GB VRAM).
- **Thư viện hỗ trợ:** Unsloth, PyTorch, Transformers.

Quá trình huấn luyện sử dụng hàm mất mát **Cross-Entropy Loss** tiêu chuẩn cho các mô hình sinh ngôn ngữ, với mục tiêu tối thiểu hóa sai lệch giữa phân phối xác suất của từ dự đoán và từ thực tế (Ground truth).

3.2. Độ đo đánh giá (Evaluation Metrics)

Để đánh giá chất lượng hệ thống OCR, chúng tôi sử dụng các độ đo sau:

1. **Character Error Rate (CER):** Đây là độ đo chính, được tính dựa trên khoảng cách Levenshtein (số thao tác sửa, xóa, thêm ký tự tối thiểu).

$$CER = \frac{S + D + I}{N}$$

   Trong đó: S, D, I lần lượt là số ký tự thay thế, xóa, và thêm vào; N là tổng số ký tự của nhãn gốc. *Đối với tiếng Việt, CER phản ánh chính xác khả năng nhận diện các dấu thanh.*

   Ngoài chỉ số CER tổng hợp (Total CER) tính trên toàn bộ tập dữ liệu, còn các chỉ số thống kê trên từng mẫu riêng lẻ còn được phân tích để có cái nhìn sâu hơn về hiệu năng của mô hình:

   - **Mean/Median CER:** Cho biết mức lỗi trung bình và mức lỗi trung vị (lỗi của một mẫu "điển hình").
   - **Min/Max CER:** Cho thấy biên độ hiệu năng của mô hình, từ trường hợp tốt nhất đến tệ nhất.

2. **Word Error Rate (WER):** Tương tự CER nhưng tính trên cấp độ từ, đánh giá khả năng hiểu ngữ nghĩa của văn bản.

3.3. Kịch bản đánh giá

Tiến hành hai kịch bản đánh giá:

- **Kịch bản 1 (Baseline Zero-shot):** Sử dụng mô hình gốc, cung cấp ảnh và prompt "Free OCR", yêu cầu mô hình sinh văn bản mà không qua bất kỳ bước cập nhật trọng số nào. Kết quả này đóng vai trò làm mốc so sánh cơ sở.
- **Kịch bản 2 (Fine-tuned Inference):** Sử dụng mô hình sau 150 bước huấn luyện, load lại trọng số LoRA adapters và thực hiện suy diễn trên cùng tập dữ liệu.

4. Kết quả và Thảo luận

4.1. Kết quả định lượng (Quantitative Results)

Bảng 2 trình bày và so sánh chi tiết hiệu năng của mô hình trước (Baseline) và sau khi tinh chỉnh (Fine-tuned) trên tập dữ liệu kiểm tra.

Bảng 2: So sánh hiệu năng chi tiết giữa Baseline và Fine-tuned Model

Chỉ số	**Baseline (%)**	**Fine-tuned (%)**
Total CER	32.21	**14.08**
Mean CER	32.47	14.11
Median CER	28.11	12.22
Min CER	0.00	0.00
Max CER	131.11	75.00
Total WER	66.74	**33.58**

Nhận xét: Kết quả cho thấy việc tinh chỉnh đã cải thiện đáng kể hiệu năng của mô hình trên mọi phương diện.

Cụ thể, chỉ số lỗi ký tự tổng hợp (Total CER) đã giảm hơn một nửa, từ 32.21% xuống chỉ còn **14.08%**, tương đương mức giảm tuyệt đối là **18.13%**. Tương tự, lỗi mức từ (Total WER) cũng giảm mạnh từ 66.74% xuống còn **33.58%**.

Một điểm đáng chú ý là sự cải thiện ở các trường hợp khó: Max CER (lỗi trên mẫu tệ nhất) đã giảm từ 131.11% xuống 75.00%, cho thấy mô hình sau khi tinh chỉnh đã ổn định và ít mắc lỗi nghiêm trọng hơn. Các chỉ số Mean và Median CER cũng xác nhận xu hướng cải thiện tích cực này. Điều này khẳng định mạnh mẽ hiệu quả của phương pháp QLoRA trong việc thích nghi mô hình với dữ liệu OCR tiếng Việt chỉ sau một số lượng bước huấn luyện hạn chế.

4.2. Phân tích quá trình huấn luyện

Sự ổn định của quá trình huấn luyện được thể hiện rõ qua sự hội tụ của hàm mất mát trên tập kiểm định (Validation Loss). Cụ thể, Validation Loss đã giảm đều đặn từ **0.933** (ở bước 10) xuống mức thấp nhất là **0.549** tại bước cuối cùng (150).

Mặc dù Training Loss có sự dao động, việc Validation Loss liên tục giảm cho thấy mô hình đang tổng quát hóa tốt các đặc trưng dữ liệu và chưa có dấu hiệu của hiện tượng quá khớp (overfitting).

[150/150 2:01:34, Epoch 0/1]

Step	Training Loss	Validation Loss
10	1.389900	0.933490
20	0.853000	0.798946
30	0.988200	0.738998
40	0.682900	0.712972
50	0.735800	0.676021
60	0.887900	0.659036
70	0.905200	0.630777
80	0.789500	0.603695
90	0.598500	0.579497
100	0.773200	0.569646
110	0.920400	0.564215
120	0.624100	0.560074
130	0.570500	0.554385
140	0.811100	0.549754
150	0.647800	0.548822

Hình 1: Bảng giá trị Validation Loss theo thời gian

4.3. Kết quả trực quan

Hình 2 minh họa sự khác biệt rõ rệt trong đầu ra của hai mô hình:

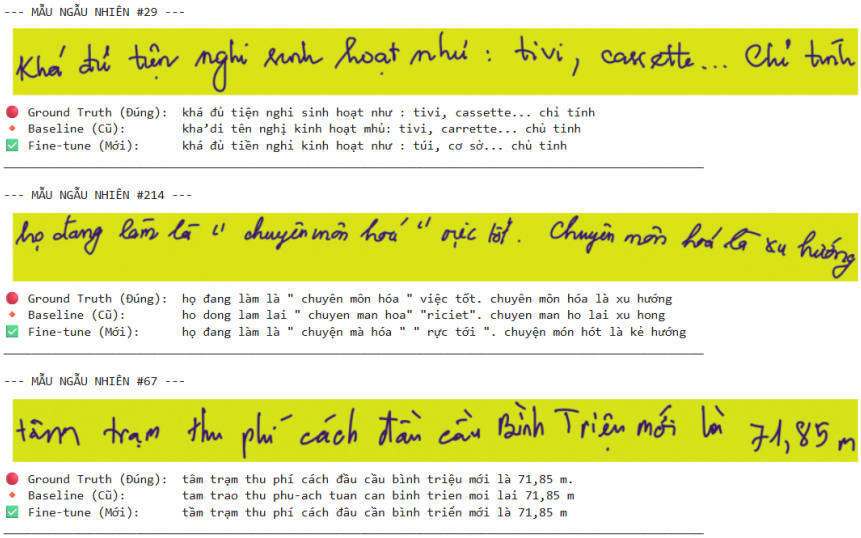

Hình 2: So sánh thực tế: Baseline và Fine-tuned

Phân tích chi tiết từ hình ảnh:

- **Khả năng phục hồi dấu thanh:** Đây là cải thiện rõ rệt nhất. Quan sát mẫu #67 và #214, mô hình Baseline gần như bỏ qua toàn bộ dấu tiếng Việt hoặc đoán sai hoàn toàn (ví dụ: *"bình triệu"* bị biến thành *"binh trien"*, *"xu hướng"* thành *"xu hong"*). Ngược lại, mô hình Fine-tuned nhận diện và đặt dấu chính xác cho các cụm từ phức tạp như *"họ đang làm là"*, *"trạm thu phí"*.

- **Khắc phục từ vô nghĩa:** Khi gặp các nét chữ cẩu thả hoặc dính nét, Baseline thường sinh ra các chuỗi ký tự không có trong từ điển (ví dụ: *"riciet"* ở mẫu #214 hay *"mhủ"* ở mẫu #29). Mô hình Fine-tuned, nhờ được huấn luyện lại, đã học được cấu trúc từ vựng tiếng Việt nên luôn cố gắng sinh ra các từ có nghĩa, giúp câu văn trở nên dễ hiểu hơn ngay cả khi ảnh đầu vào có chất lượng thấp.

4.4. Thảo luận và Hạn chế

Mặc dù kết quả khả quan, hệ thống vẫn còn một số thách thức cần giải quyết:

- **Giới hạn phần cứng:** Việc sử dụng GPU T4 buộc phải giới hạn Batch size nhỏ (2). Nếu được huấn luyện trên phần cứng mạnh hơn (A100) với độ dài ngữ cảnh lớn hơn, mô hình có thể xử lý tốt hơn các văn bản dài.

- **Dữ liệu huấn luyện:** Số lượng 3.200 mẫu tuy đủ để hội tụ nhưng vẫn khiêm tốn so với sự đa dạng của chữ viết tay. Việc mở rộng tập dữ liệu hứa hẹn sẽ giảm CER xuống dưới 10%.

5. Kết luận

Đồ án này đã xây dựng và thực nghiệm thành công quy trình tinh chỉnh (Fine-tuning) Mô hình Ngôn ngữ Đa phương thức Lớn cho bài toán nhận dạng văn bản tiếng Việt. Việc áp dụng kỹ thuật **QLoRA** thông qua thư viện Unsloth đã chứng minh được tính khả thi của việc huấn luyện các mô hình AI hiện đại trên tài nguyên phần cứng hạn chế (GPU T4) mà vẫn đảm bảo hiệu năng cao. Các đóng góp và kết quả chính của đồ án bao gồm:

- **Cải thiện độ chính xác:** Mô hình sau khi tinh chỉnh đạt tỷ lệ lỗi ký tự (CER) **14.08%** và tỷ lệ lỗi từ (WER) **33.58%**. Đây là mức cải thiện vượt bậc so với mô hình Baseline, đặc biệt trong việc xử lý chính xác hệ thống dấu thanh và nguyên âm phức tạp của tiếng Việt.
- **Khả năng xử lý dữ liệu thực tế:** Thay vì chỉ nhận dạng tốt các văn bản in chuẩn, mô hình đã học được cách xử lý các biến thể đa dạng của **chữ viết tay** và các ảnh có chất lượng không đồng đều. Điều này khắc phục hạn chế lớn nhất của các mô hình nền tảng vốn chưa được tối ưu cho đặc thù chữ viết người Việt.
- **Tối ưu hóa tài nguyên:** Dồ án khẳng định rằng với phương pháp tiếp cận đúng đắn (sử dụng Quantization và Low-Rank Adaptation), sinh viên và cộng đồng nghiên cứu có thể tự xây dựng các mô hình OCR chuyên biệt chất lượng cao mà không nhất thiết phải phụ thuộc vào các siêu máy tính đắt tiền.

Kết quả của đồ án đóng vai trò là tiền đề vững chắc cho việc ứng dụng các mô hình ngôn ngữ thị giác (VLM) vào các bài toán OCR tài liệu tiếng Việt trong tương lai.

6. Mã nguồn và Tài nguyên (Source Code)

Toàn bộ mã nguồn huấn luyện, đánh giá và các tài liệu liên quan của đồ án được lưu trữ công khai tại GitHub Repository dưới đây:

- **GitHub Repository:**
  https://github.com/pqthinh232/Fine-tune-Deepseek-OCR-with-Vietnamese-Dataset.git
- **Nội dung bao gồm:**
  - Notebook huấn luyện và đánh giá (`.ipynb`) với đầy đủ log chạy thực tế.
  - Hướng dẫn cài đặt môi trường và tái lập kết quả.
  - Link tải Model Checkpoint (đã lưu trên Google Drive).

Tài liệu

[1] Dettmers, T., Pagnoni, A., Holtzman, A., & Zettlemoyer, L. (2023). *QLoRA: Efficient Finetuning of Quantized LLMs*. arXiv preprint arXiv:2305.14314. https://arxiv.org/pdf/2305.14314

[2] Unsloth AI. *DeepSeek-OCR: How to Run & Fine-tune*. Truy cập ngày 15/01/2025. https://docs.unsloth.ai/models/deepseek-ocr-how-to-run-and-fine-tune

[3] Nguyen, N. H., Vo, D. T. D., & Nguyen, K. V. (2022). "UIT-HWDB: Using Transferring Method to Construct A Novel Benchmark for Evaluating Unconstrained Handwriting Image Recognition in Vietnamese". *2022 RIVF International Conference on Computing and Communication Technologies*. IEEE, pp. 659–664. https://github.com/nghiangh/UIT-HWDB-dataset